Notes du laboratoire de microprocesseur (MIC2-micl)

Nathan Furnal

15 mars 2021

Table des matières

1	Intr	roduction	2
2	Lab	oratoire 1 : Prise en main	2
	2.1	Registres	2
	2.2	Langage d'assemblage	2
	2.3	Exécution et déboguage	3
3	Lab	oratoire 2 : Instructions logiques et de manipulation de bits	3
	3.1	Valeurs booléennes	3
	3.2	Registre rflags	3
	3.3	Instructions logiques	3
		3.3.1 not	3
		3.3.2 and, or, xor	3
		3.3.3 Masquage	4
	3.4	Instruction de manipulation de bits : bt, bts, btr, btc	4
	3.5	Exercices	4
		3.5.1 Exercice 1	4
		3.5.2 Exercice 2	4
		3.5.3 Exercice 3	5
		3.5.4 Exercice 4	5
4	Lab	oratoire 3 : Instructions de saut et alternatives	5
_	4.1	Comparaison cmp	5
	4.2	Label	6
	4.3	Branchement	6
		4.3.1 Saut inconditionnel jmp	6
		4.3.2 Sauts conditionnels jf et jnf	6
		4.3.3 Applications	7
	4.4	Alternative	7
		4.4.1 Alternative si	7
		4.4.2 Alternative si-sinon	7
	4.5	Exercices	8
		4.5.1 Exercice 1	8
		4.5.2 Exercice 2	8
		4.5.3 Exercice 3	9
		4.5.4 Exercice 4	9
		4.5.5 Exercice 5	9
5	Lab	oratoire 4 : Variables globales	10
	5.1	Sections dédiées aux variables	10
	5.2	Accès à une variable	11
		5.2.1 Boutisme	11
	5.3	Amnésie de nasm	12
		5.3.1 Problème de taille	12
			13
	5.4	Type de données	13
		5.4.1 Entier	13
		5.4.2 Flottant	13
		5.4.3 Caractère	13
	5.5	Exercices	13

		Exercice 1 : remplir les pointillés	13
	5.5.2	Exercice 2	14
	5.5.3	Exercice 3	14
	5.5.4	Exercice 4	15
	5.5.5	Exercice 5	15
	5.5.6		16
Labo	oratoire	5 : Appels système	16
5.1	Définit	ion	16
5.2	Mise e	nœuvre	16
5.3	Registr	res non préservés	17
5.4	Numér	o du service	17
5.5	Paramè	etre et retour	17
5.6	Entrée	et sorties standards	18
5.7	Hello	, World!	18
6.8 Cinq appels système		ppels système	18
			19
	6.9.1	Ouvrir un fichier	19
	6.9.2	Ouverture et écriture	19
	6.9.3	Convertir rsi en caractères	20
	6.9.4	Afficher la parité	20
	6.9.5		21
	6.9.6		22
	6.1 6.2 6.3 6.4 6.5 6.6 6.7	5.5.3 5.5.4 5.5.5 5.5.6 2aboratoire 6.1 Définit 6.2 Mise en 6.3 Registr 6.4 Numér 6.5 Paramè 6.6 Entrée 6.7 Hello 6.8 Cinq ap 6.9 Exerció 6.9.1 6.9.2 6.9.3 6.9.4 6.9.5	5.5.3 Exercice 3 5.5.4 Exercice 4 5.5.5 Exercice 5 5.5.6 Exercice 6 Laboratoire 5 : Appels système 1.1 Définition 1.2 Mise en œuvre 1.3 Registres non préservés 1.4 Numéro du service 1.5 Paramètre et retour 1.6 Entrée et sorties standards 1.7 Hello, World! 1.8 Cinq appels système 1.9 Exercices 1.9 Exercices 1.9 Ouvrir un fichier 1.9 Convertir rsi en caractères 1.9 Afficher la parité 1.9 Écrire des fichiers

1 Introduction

Dans ce laboratoire, on va étudier les instructions des microprocesseurs en 64 bits, plus particulièrement la famille x86. Le but est de pouvoir effectuer des opérations simples en langage assembleur et de les déboguer.

2 Laboratoire 1 : Prise en main

2.1 Registres

Tout d'abord on doit définir ce qu'est un **registre**. C'est une zone de mémoire au sein du microprocesseur qui est très rapide d'accès. Une autre notion importante est celle de **opcode** ou code opérateur. Les instructions notées en hexadécimal commencent par un **opcode** qui désigne le type d'opération que l'on exécute, suivies par l'endroit en mémoire sur lequel porte l'opération.

De ce fait, le nom du registre est important (rax, rsi, r8,...) car il désigne le type d'opération qu'on va effectuer ou le type d'opération concernée par une autre commande qu'on exécute. En effet, certains registres sont directement modifiés par l'utilisateur et d'autres sont modifiés par d'autres opérations ou programmes sans action directe de l'utilisateur.

Par exemple, le registre rip pour «register of instruction pointer», stocke l'adresse de l'instruction à exécuter *après* celle en cours d'exécution. D'autres registres seront détaillés plus tard.

2.2 Langage d'assemblage

On trouve les codes sources assembleur dans le premier TD. On y voit surtout des instructions pour stocker des valeurs en mémoire et puis les déplacer de registre en registre.

Un code source en langage d'assemblage est constitué de directives au compilateur, d'instructions, d'identifiants, d'immédiats, de commentaires et d'étiquettes (*labels*).

```
global main
section .text
main:
nop; ne fait rien

; met l'immédiat en hexadécimal dans le registre rax
; grâce à l'instruction mov
mov rax, 0x1122334455667788
```

On peut voir le code global main qui est une directive, une information pour le compilateur qui n'est pas une instruction. Elle n'exécute pas directement du code mais informe sur *comment* le code être compilé. Dans le cas d'une instruction comme mov rsi, -1 la destination est le registre rsi et la source est la valeur immédiate -1. Enfin, mov est le mnémonique qui décrit une opération.

Le programme se termine, sous GNU/Linux par l'instruction syscall, qui est un *appel système*, expliqué dans le cours théorique.

2.3 Exécution et déboguage

Les parties suivantes expliquent comment rendre le fichier .nasm exécutable et comment le déboguer via un outil comme kdbg.

3 Laboratoire 2 : Instructions logiques et de manipulation de bits

TD sur les manipulations de bits.

3.1 Valeurs booléennes

Il y a deux valeurs booléennes, *Vrai* ou *Faux*. Un seul bit suffit pour déterminer la variable booléenne. On code *Vrai* par 1 et *Faux* par 0.

3.2 Registre rflags

Le registre rflags est un registre de 64 bits dont certains des indicateurs (drapeaux, *flags*). Son équivalent sur 32 bits est le registre eflags, c'est le registre des états des processeurs x86 32bits donc. Les 32 nouveaux bits de poids 32 à 63 dans rflags sont tous réservés. Les indicateurs fournissent de l'information sur le déroulement des processus en cours. On parle de *status flag* car ils permettent de savoir comment les opérations arithmétiques se sont déroulées.

```
Carry Flag (CF) indicateur de retenue, bit de rang 0 dans rflags.
```

Zero flag (ZF) indicateur de zéro, bit de rang 6 dans rflags.

Sign flag (SF) indicateur de signe, bit de rang 7 dans rflags.

Overflow flag (OF) indicateur de débordement, bit de rang 11 de rflags.

On ne peut pas accéder directement au contenu de rflags mais on peut y accéder indirectement via des instructions qui seront expliquées plus tard. De ce fait, on ne doit pas nécessairement connaître les positions précises des *flags*.

3.3 Instructions logiques

3.3.1 not

L'instruction not n'a qu'un opérande qui joue le rôle de source et de destination en même temps, pour les registres ou les variables de 8 à 64 bits. Elle **inverse** tous les bits de son opérande.

```
al: 10011101b
not al
al: 01100010b
```

3.3.2 and, or, xor

Les instructions and, or, xor ont deux opérandes : la *destination* à gauche de la virgule et la *source*, à droite. Ces opérandes peuvent être des registres ou des variables de 8 à 64 bits mais pas tous les deux des emplacements mémoire. En outre, la *source* peut être un immédiat (un nombre).

Ces instructions effectuent respectivement un et, ou et un ou exclusif logique bit à bit entre la source et la destination. Ils placent le résultat dans la destination sans modifier la source.

De plus, ces instructions modifient le *sign flag* qui reçoit le bit de rang plus élevé du résultat et le *zero flag* qui indique si le résultat est nul : 1 pour nul et 0 pour non nul. Le *carry flag* et le *overflow flag* sont mis à zéro. Voici quelques exemples. Les tables résumées sont dans le document du TD.

Attention, les immédiats s'étendent sur maximum 32 bits. Si on utilise un immédiat avec une destination dont la taille fait 64 bits, l'immédiat est étendu sur 64 bits par extension de signe : son bit de signe, celui de rang 31, est recopié en bits 32 à 63.

3.3.3 Masquage

Le masquage consiste à effectuer une opération logique afin de conserver certains bits d'un opérande et d'en modifier d'autres. Ils s'effectuent avec and, or et xor. Pour utiliser un masque, on utilise une des instructions ou le second opérande est un masque qu'on désire utiliser. Comme toujours les tables récapitulatives sont le document du TD2.

- 1. and
 - L'instruction and permet de conserver certains bits d'un opérande et mettre les autres à zéro.
- 2 or
 - L'instruction or permet de conserver certains bits d'un opérande et mettre les autres à zéro.
- 3. xor

L'instruction xor permet de conserver certains bits d'un opérande et d'inverser les autres.

3.4 Instruction de manipulation de bits : bt, bts, btr, btc

L'instruction bt signifie bit test et test un bit précis d'un motif binaire donné. Les instructions bts (bit test and set), btr (bit test and reset) et btc (bit test and complement), testent également un bit avant de le mettre à 1, 0 ou de le complémenter, respectivement.

Le premier opérande de ces instructions est un registre ou une variable de 16, 32 ou 64 bits. Le second opérande est un registre de 16, 32 ou 64 bits ou un immédiat sur 8 bits. Si le deuxième opérande est un registre, il doit être de même taille que le premier.

Ces quatre instructions copient dans le *carry flag* le bit du premier opérande dont le rang est fourni via le second opérande. C'est la partie *test* à laquelle se limite bt.

Ensuite l'instruction:

- bts met ce bit du premier opérande à 1.
- btr met ce bit du premier à 0.
- btc complémente ce bit du premier opérande.

Le zero flag n'est pas modifié. L'overflow flag et le sign flag sont indéfinis.

3.5 Exercices

3.5.1 Exercice 1

Application directe des masques et manipulation

3.5.2 Exercice 2

```
; exercice 2 du td 2 de MICL
2
    global main
    {\tt section .text}
    main:
    ;;; 'd' : 0110 0100b
    ;;; and : 0101 1111b
7
              0100 0100b
    ;;; 'D' : 0100 0100b
9
        mov ah, al
10
        and ah, 01011111b
11
12
13
        ; fin
        mov rax, 60
14
```

```
mov rdi, 0
syscall
```

3.5.3 Exercice 3

```
global main
section .text
main:

mov bx, 'd' ; charge le caractère 'd' dans le registre al
btc bx, 5 ; complémentaire du bit en position 5

;; fin
mov rax, 60
mov rdi, 0
syscall
```

3.5.4 Exercice 4

```
;; exercice 4 du td 02 de MICL
2
   global main
   section .text
   main:
5
           mov bl, 00000101b ; 5 en binaire
           ;; On veut donner la valeur en ascii
            ;; masque `or` pour passer en ascii
           or bl, 00110000b
            ;; fin
10
           mov rax, 60
11
            mov rdi, 0
12
            syscall
```

4 Laboratoire 3 : Instructions de saut et alternatives

Ce TD présente L'instruction cmp et la notion de *label* est abordée. Ensuite, on traite de l'instruction jmp qui permet de faire un saut sans condition. Finalement, les instructions de saut conditionnel, dépendant de la valeur des *flags* jf et jnf sont montrées ainsi que l'implémentation des alternatives *si* et *sinon*.

4.1 Comparaison cmp

L'instruction cmp a deux opérandes de même taille. Ils peuvent être des registres ou des variables de 8, 16, 32 ou 64 bits. Il ne peuvent cependant pas tous les deux être des variables. L'opérande de droite peut être un immédiat.

Cette instruction compare l'opérande de gauche et de droite. Elle positionne les *flags* du registre **rflags** comme le ferait une soustraction de ceux-ci mais ne modifie aucun de ses opérandes.

```
;; Montrer l'usage de cmp avec des commandes simples
   global main
   section .text
3
   main:
           mov rax, 4
                                       ; ZF : 1 (4 - 4 == 0), SF: 0 (4 - 4 >= 0)
            cmp rax, 4
                                       ; ZF : 0 (4 - 5 != 0), SF: 1 (4 - 5 < 0)
            cmp rax, 5
                                       ; ZF : 0 (4 - 2 != 0), SF: 0 (4 - 2 >= 0)
            cmp rax, 2
10
            ;; fin
11
            mov rax, 60
```

```
mov rdi, 0
syscall
```

On peut donc voir que le *zero flag* et le *sign flag* sont affectés par la comparaison. Il faut noter que dans les cas plus extrêmes d'*overflow*, l'*overflow flag* est levé. Aussi, si une opération requiert plus de bits que la taille maximale du registre, le *carry flag* sera levé lui aussi.

Un immédiat peut être codé sur au plus 32 bits et dans le cas où il est comparé à un opérande de 64 bits, l'extension de signe rendre en jeu. L'extension de signe se déroule de la manière suivante, avec un immédiat de 32 bits et un registre de 64 bits. Prenons une valeur de 0x80_80_80_80.

- En binaire : $0x80_80_80_80 \rightarrow 0b10000001000000100000010000000$.
- On remarque que le bit de poids le plus fort est 1.
- On étend ce 1 sur les 32 nouveaux bits de poids fort dûs au passage du 32 au 64 bits, ce qui donne en binaire :
- On reconvertit en hexadécimal, on a bien : 0xFF_FF_FF_FF_80_80_80_80.

Il faut noter que l'extension de signe n'arrive **pas** avec le mnémonique mov.

4.2 Label

UN *label* est un repère que le programmeur met dans le code afin de donner un nom à une ligne de programme. Pour signaler le début de programme, on utilise le label main par exemple. La définition d'un label se termine par le caractère : qui ne fait <u>pas</u> partie du nom du label. Il peut contenir des chiffres, des lettres ou un *underscore* mais doit commencer par une lettre, un *underscore* ou un point.

4.3 Branchement

En assembleur, les instructions sont exécutées les unes après les autres, dans l'ordre où elles se trouvent dans la mémoire centrale. On parle d'exécution **séquentielle**. On appelle *saut* ou *branchement* le fait de passer d'une instruction à une autre qui ne la suit pas directement en mémoire. C'est le cas lorsqu'on a des alternatives (*if*, *else*) ou bien des boucles (*for*, *while*).

Ce TD aborde les sauts inconditionnels (jmp) et les sauts conditionnels : jf et jnf.

4.3.1 Saut inconditionnel jmp

L'instruction jmp permet d'effectuer un saut vers un *label*. On parle de saut inconditionnel car il a lieu dans tous les cas, sans aucune condition. Cette instruction ne nécessite que le label de la position vers laquelle on veut sauter, et ne modifie aucun *flag*.

```
mov rax, 123
mov rbx, 150

jmp fin ; saut inconditionnel vers la fin

mov rax, 0 ; jamais exécuté
mov rbx, 0 ; jamais exécuté

mov rbx, 0 ; jamais exécuté

mov rax, 60
mov rax, 60
mov rdi, 0
syscall
```

Par ce saut vers le label, les instructions après le saut et avant le label ne sont jamais exécutées.

4.3.2 Sauts conditionnels jf et jnf

Les instructions de saut conditionnel permettent d'effectuer un saut si une certaine condition est vraie. Le f dans les expressions, représente un flag. Par exemple, jc représente un saut suivant le carry flag et jnz représente un saut dépendant du zero flag.

Le saut conditionnel jf permet de vérifier si un flag donné est à 1.

Le saut conditionnel jnf permet de vérifier si un flag donné est à 0.

4.3.3 Applications

Une fois qu'on à ces outils en main, on peut les utiliser pour sauter vers les instructions qui nous intéresse, en fonction du *flag* qu'on a choisi d'analyser.

Voici par exemple un test de parité, si le *carry flag* vaut 1, du au *bit test* alors on va vers la fin; sinon on exécute l'instruction suivante.

```
bt rax, 0 ;; Test de parité, est ce que le premier bit vaut zéro
jc endIf
mov rbx, 5
endIf:
mov rcx, 12
```

Ici on teste l'infériorité, on compare rax à une valeur. Ensuite, si le *sign flag* est levé (pour les résultats négatifs) alors on va vers le saut, sinon on exécute l'instruction suivante.

```
cmp rax, -10
jns endIf
mov rbx, 5
endIf:
mov rcx, 12
```

Ici, on teste l'inégalité, on compare rax avec rdx. La comparaison induit une différence temporaire donc s'ils contiennent les mêmes valeurs, le *zero flag* sera levé et on pourra exécuter un saut et sinon, on va vers l'instruction suivante.

```
cmp rax, rdx
jz endIf
mov rbx, 5
endIf:
mov rcx, 12
```

4.4 Alternative

4.4.1 Alternative si

En fait, ce qui a été présenté au-dessus représente une alternative "si". Dans le cas où un *bit test* ou bien une comparaison est évalué, ils affectent les *flags* classiques comme le *carry flag*, *sign flag* ou *zero flag* on peut les utiliser pour aller vers le label désigné par jmp.

4.4.2 Alternative si-sinon

La logique est parfaitement identique quand on veut avoir deux branches, le si et le sinon. On utilisera deux labels avec chacun une instruction et l'exécution de l'un ou l'autre suivra de la condition.

Voici un exemple de test de parité, on insère la valeur du premier bit de rax dans le *carry flag*. Si ce bit vaut zéro (rax est pair) alors on n'exécute **pas** le saut vers _sinon et rbx vaut 5. Puis on va vers la fin. S'il s'avère ne pas être pair, on effectue l'instruction au label _sinon et rbx vaut 6.

```
bt rax, 0
jc _sinon
mov rbx, 5
jmp _fin_si
s _sinon:
mov rbx, 6
fin_si:
mov rcx, 12
```

Voici un exemple de test d'infériorité :

```
cmp rax, -10
jns _sinon
mov rbx, 5
jmp _fin_si
s _sinon:
mov rbx, 6
fin_si:
mov rcx, 12
```

Voici un exemple de test d'inégalité :

```
cmp rax, rdx
jns _sinon
mov rbx, 5
jmp _fin_si
sinon:
mov rbx, 6
fin_si:
mov rcx, 12
```

4.5 Exercices

4.5.1 Exercice 1

```
;;; TD3 Exo 1
   global main
3
   section .text
   main:
           mov rax, 42
                                       ; Met 10 dans rax
           cmp rax, 0
           jnz _if_not_null
8
           jmp _end
10
   _if_not_null:
          mov rbx, 1
11
   _end:
12
          mov rax, 60
          mov rdi, 0
14
           syscall
15
```

4.5.2 Exercice 2

```
;;; TD3 Exo 2
   global main
   section .text
   main:
           mov rax, 42
6
           bt rax, 0
7
           jc _if_not_even
           mov r8, 0
10
           jmp _end
   _if_not_even:
11
           mov r8, 1
12
13
    _end:
           mov rax, 60
14
           mov rdi, 0
15
           syscall
```

4.5.3 Exercice 3

```
;;; TD3 Exo 3
2
   global main
   section .text
   main:
            mov r14, 42
           mov r15, 43
           cmp r14, r15
9
            jnz _if_not_equal
            mov r14, 0
11
            mov r15, 0
12
            jmp _end
13
14
15
    _if_not_equal:
           xor r14, r15
16
           xor r15, r14
17
           xor r14, r15
19
           mov rax, 60
20
           mov rdi, 0
21
            syscall
22
23
   ;;; Ici on utilise le xor swap, sachant que le xor est commutatif
24
   ;;; 1. xor r14, r15 applique le xor et stocke le résultat dans r14
   ;;; 2. xor r15, r14 applique le xor et stocke le résultat dans r15
   ;;; 3. xor r14, r15 applique le xor et stocke le résultat dans r14
   ;;; En pratique les étapes font pour x valant 1010 et y valant 0011
   ;;; xor x, y <=> xor 1010, 0011 = 1001 -> x
   ;;; xor y, x \iff xor 0011, 1001 = 1010 \implies y
   ;;; xor x, y <=> xor 1001, 1010 = 0011 -> x
```

4.5.4 Exercice 4

```
;;; TD3 Exo 4
   global main
   section .text
   main:
6
            mov rax, 42
7
            mov rbx, 11
            cmp rax, rbx
            js _rax_is_less
9
            mov r8, rax
            mov r9, rbx
11
            jmp _end
12
    _rax_is_less:
13
           mov r8, rbx
14
           mov r9, rax
15
    _end:
16
17
            mov rax, 60
            mov rdi, 0
            syscall
```

4.5.5 Exercice 5

```
;;; TD3 Exo 5
2
3 global main
```

```
section .text
    main:
5
            mov rdi, 11
                                      ; CF vaut 0 si au moins multiple de 2
            bt rdi, 0
            ;; On envoie vers les multiples de 2 sinon on termine
            jnc _if_even
            mov rsi, 0
10
            jmp _end
    _if_even:
12
            mov rsi, 1
13
                                         ; CF vaut 0 si au moins multiple de 4
            bt rdi, 1
14
            ;; On envoie vers les multiples de 4 sinon on termine
15
            jnc _if_multiple_of_4
16
            jmp _end
17
18
19
    _if_multiple_of_4:
            mov rsi, 2
20
            bt rdi, 2
                                       ; CF vaut 0 si au moins multiple de 8 au plus
21
            ;; On envoie vers les multiples de 8 sinon on termine
22
            jnc _if_multiple_of_8
            jmp _end
24
25
    _if_multiple_of_8:
26
            mov rsi, 3
27
    _end:
28
            mov rax, 60
29
            mov rdi, 0
            syscall
```

5 Laboratoire 4 : Variables globales

Ce laboratoire va traiter des **variables globales**, elles sont généralement déclarées en début de code et utilisables dans **tout** le fichier. On oppose ce comportement aux variables **locales**.

5.1 Sections dédiées aux variables

Un fichier binaire exécutable au format elf est divisé en plusieurs sections. La **directive** section permet de les définir dans le code source du programme. D'habitude, on utilise la section .text qui contient les instructions exécutables du programme. Les sections elf standards pour les variables globales sont au nombre de trois : .data, .rodata, .bss. Les variables crées dans ces sections ont la même durée de vie que le programme, c'est-à-dire qu'elles apparaissent à sa création et disparaissent après.

Les variables en assembleur ne sont pas *typées*, on doit seulement fournir leur taille. Ensuite, elles sont mises l'une après l'autre en mémoire. Pour les sections .data et .rodata, les variables sont explicitement créées et sont dans le programme.

Nom	Rôle		
.text	Instructions exécutables du programme		
.data Variables globales explicitement initialisées			
.rodata	Variables globales explicitement initialisées en lecture seule		
.bss	Variables globales implicitement initialisées à zéro		

Voici les instructions qui permettent de définir la taille attribuée aux variables :

Taille en bytes	Pseudo-instruction	Signification
1	DB	Define Byte
2	DW	D efine W ord
4	DD	D efine D oubleword
8	DQ	D efine Q uadword

Enfin, voici un exemple d'utilisation en assembleur :

```
section .data
2 i1 DB -1 ; 1 byte initialisé
```

```
i2 DW 23 ; 2 bytes initialisés

i4 DD -1 ; 4 bytes initalisés

i8 DQ 0x80_00_00_00 ; 8 bytes initialisés donc 0x00_00_00_00_00

section .rodata

ci8 DQ 93229

section .text

;...
```

Attention, les variables .bss ne sont littéralement présentes dans le fichier exécutable, elles sont créées et mises à zéro lors du démarrage du programme.

Voici les instructions liées à cette section ainsi qu'un exemple.

Taille en bytes	Pseudo-instruction	Signification
1	RESB	Reserve Byte
2	RESW	Reserve Word
4	RESD	Reserve Doubleword
8	RESQ	Reserve Quadword

Dans le code source, on met un entier pour indiquer combien de *bytes*, *words*, ou *double words* sont réservés en mémoire au début du programme.

```
section .bss

; tout est crée et initalisé à 0

x1 RESB 10 ; 10 * 1 bytes réservés

x2 RESW 6 ; 6 * 2 bytes réservés

x4 RESD 100 ; 100 * 4 bytes réservés

x8 RESQ 2 ; 2 * 8 bytes réservés
```

5.2 Accès à une variable

Le nom d'une variable est en fait un label, une étiquette. Son utilisation dans le code source est remplacée par l'*adresse* de l'emplacement où l'étiquette est placée. Cela correspond à l'adresse de la variable lorsqu'on est dans les sections décrites au-dessus. Rappelons que nous travaillons en 64 bits. Les adresses de variables ont donc toujours cette taille, soit 8 *bytes*.

Pour accéder au *contenu* de la variable, il faut réaliser un **déréférencement** : atteindre ce qui se trouve à l'adresse de la variable. Pour indiquer à *nasm* qu'on désire déréférencer un **pointeur**, on place l'adresse entre crochets. Voici un exemple.

```
section .data
       i4 DD 42
                               ; entier sur 4 bytes
2
3
    section .text
4
                               ; rax <-- _adresse_ (8 bytes) de i4.
       mov rax, i4
5
                               ; ebx <-- _contenu_ de ce qui se trouve
       mov ebx, [i4]
7
                               ; à l'adresse i4 dans ebx.
                               ; s'étend sur 4 bytes car ebx est sur 4 bytes.
10
                               ; rax contient l'adresse de i4 donc [rax] = [i4].
       mov ecx, [rax]
11
                               ; donc, ecx <-- _contenu_ de l'adresse rax.
12
                               ; s'étend sur 4 bytes car ecx est sur 4 bytes.
```

5.2.1 Boutisme

Lorsqu'on stocke des données en mémoire, on peut suivre deux stratégies pour ordonnancer les *bytes*. Soit on met le byte de rend le plus élevé à l'adresse la plus petite, c'est le *big endian*. Soit on met le byte de rend le plus petit à la plus petite adresse, c'est le *little endian*. L'architecture x86 adopte le *little endian*.

Voici un exemple qui en illustre l'usage pour comprendre comment les adresses logiques sont mises l'une à la suite de l'autre et comment accéder aux valeurs stockées en *little endian*.

```
section .data
1
        vw DW 0x0102 ; Valeur en hexadécimal stockée sur 4 bytes
2
    ;; à l'adresse vw : 0x02
   ;; à l'adress vw + 1 : 0x01
    ;; |...|...|0x02|0x01|...|...|
    ;; -> petite adresse --> grande adresse -->
        vq DQ 0x1122334455667788
9
10
   ;; à l'adresse vq : 0x88
11
   ;; à l'adresse vq+1 : 0x77
   ;; à l'adresse vq+2 : 0x66
13
   ;; à l'adresse vq+3 : 0x55
14
    ;; à l'adresse vq+4 : 0x44
15
    ;; à l'adresse vq+5 : 0x33
    ;; à l'adresse vq+6 : 0x22
17
    ;; à l'adresse vq+7 : 0x11
18
19
    ;; |...|0x88|0x77|0x66|0x55|0x44|0x33|0x22|0x11|...|
    ;; -> petite adresse --> grande adresse -->
21
22
23
    ;; vue complète de la section .data
24
    ;; | vw | vq | qu'on décompose en leurs bytes respectifs. Pas d'espaces entre adresses.
25
    ;; |...|0x02|0x01|0x88|0x77|0x66|0x55|0x44|0x33|0x22|0x11|...
26
    ;; -> petite adresse --> grande adresse -->
28
    section .text
29
30
    mov r8b, [vw]
                      ; r8b <-- 0x02
    mov r12b, [vq + 7]; r12b \leftarrow 0x11
32
33
    ;; pas de trous entre variables
34
   ;; vw est directement suivie par vq
   mov r13b, [vw+2] ; r13b \leftarrow 0x88 (plus petit byte de vq)
37
   mov r14b, [vw+3] ; r14b < -- 0x77
   mov r15b, [vq - 1] ; r15b <-- 0x01 (dernier byte de vw)
```

5.3 Amnésie de nasm

Comme il a été mentionné précédent, le nom d'une variable en code source nasm est une étiquette. La seule information à laquelle on accède en fournissant un nom de variable, c'est l'adresse à laquelle l'étiquette est placée. Aucune autre information n'est rendu disponible par nasm, ce qui créera potentiellement des problèmes par la suite.

5.3.1 Problème de taille

L'assembleur nasm ne **retient pas** la taille des variables. Lorsqu'on accède au contenu d'une variable, le nombre de *bytes* déréférencés à partir de l'adresse entre crochet est déduit de la taille du second opérande, s'il existe et n'est pas un immédiat. Dans le cas contraire, il faut renseigner la taille de la donnée avec une spécification de taille, décrite ci-dessous.

Taille en bytes	Spécificateur	
1	byte	
2	word	
4	dword	
8	qword	

L'exemple repris à la page 8 et 9 du TD4 illustre bien les problèmes qu'on peut rencontrer et comment utiliser les spécificateurs de taille. Il faut particulièrement se méfier des erreurs d'extension de signes ou d'adressage avec des tailles différentes. En ce qui concerne l'extension de signe, seule le mov avec un *registre* pour destination et un immédiat accepte le 64bit. Autrement, on aura une extension de signe qui dépend du bit de poids le plus fort.

Il y a aussi un comportement particulier quand on place une variable de 8 bytes dans un registre de 4 bytes qui a aussi un registre plus grand équivalent. Par exemple :

```
global main

section .data

var dq 0x12345678

section .text

main:

;; En plaçant une valeur de 8 bytes dans un registre de 4 bytes

;; qui a un équivalent supérieur de 8 bytes, on va vider le registre de 8 bytes

;; et ensuite seulement le remplir avec la variable définie sur 8 bytes

mov eax, [var1] ; rax -> 0x0000...00012345678
```

5.3.2 Problème de section

L'assembleur nasm ne retient pas de quelle section vient une variable. De ce fait, il nous laisse créer un programme et compiler un programme qui modifie une variable en lecture seule par exemple. Mais lors de l'exécution on aura une erreur.

5.4 Type de données

Dans cette section, nous allons passer en revue quelques types de données classiques et voir comment les implémenter en assembleur. Les chaînes de caractères sont introduites au TD05 et les tableaux au TD06.

5.4.1 Entier

Les entiers sont le cas le plus simple, il suffit de choisir une taille sur 1, 2, 4 ou 8 bytes et de réserver l'espace en conséquence.

```
vqd DQ -1 ; valeur décimale
vdh DD 0x12345678 ; valeur hexadécimale
vwo DW 114q ; valeur octale
vbb DB 10101010b ; valeur binaire
```

5.4.2 Flottant

Il existe des registres spéciaux pour les flottants mais on ne les traite pas au TD.

5.4.3 Caractère

Comme en Java, les caractères sont considérés comme un type numérique. La table ASCI associe un nombre à chaque caractère. Pour les caractères au delà de la table ASCII, on utilise généralement le codage UTF-8 sur 2 bytes.

Exemple:

```
section .data

c1 DB 'A' ; c1 contient le code UTF-8 du caractère 'A'

c2 DB 65 ; c2 contient la valeur 65

;; 65 en décimal équivaut à 0x41, qui représente le caractère 'A' en UTF-8
```

5.5 Exercices

5.5.1 Exercice 1 : remplir les pointillés

```
global main

section .data
var1 DB 1
```

```
var2 DB 2
       var3 DW 0x0304
6
       var4 DQ 0x00_00_00_00_80_00_FF_FF
7
    ;; la section des données occupe 12 bytes
   ;;; Contenu de la plus petite adresse à la plus grande
   ;;; v1 v2 v3
                      v_4
10
   ;;; ...01020403FFFF00800000000001...
11
   section .text
13
   main:
14
       mov rax, var1 ; rax contient l'adresse de var1
15
   ;; (on ne connaît pas explicitement cette adresse, c'est l'OS qui la détermine).
      mov al, [var1]; al contient 1
17
       mov ax, [var1]; ax contient 0x0201 soit 0000_0010_0000_0001b
18
    ;; Car ax est un registre sur 2 bytes, il lit la valeur sur 2 bytes
19
    ;; Donc on prend en fait les valeurs de var1 et var2
20
       mov al, [var3]; al contient 0x04 soit 0000_0100b
21
    ;; Car al est un registre sur 1 byte, on prend le premier byte de la valeur de var3
22
       mov ax, [var3] ; ax contient 0x0304 soit 0000_0011_0000_0100b
23
       mov rax, -1; rax contient 0xFF_FF_FF_FF_FF_FF_FF_FF par extension de signe
       mov eax, [var4] ; eax contient : 0x80_00_FF_FF (on ne lit que 4 byte en mémoire)
25
   ;; rax contient 0x00_00_00_00_00_80_00_FF_FF, les valeurs précédentes de rax sont écrasées
26
    ;; c'est le cas quand on utilise un registre 64bits avec une variable 32 bits.
27
       mov rax, 60
28
       mov rdi, 0
29
      syscall
```

5.5.2 Exercice 2

```
global main
   section .data
       nb dd 11 ; Essayer avec C3_D8_10_00 pour bit de poids fort différent
5
   section .text
   main:
                                    ; Placer adresse dans eax
      mov eax, nb
10
       mov ebx, [nb]
                                      ; Placer la valeur dans ebx
11
12
   ;; fin
13
14
       mov rax, 60
       mov rdi, 0
16
       syscall
17
```

5.5.3 Exercice 3

```
global main

section .bss

nb resq 1 ; On réserve 1 x 8 bytes

section .text

main:
```

```
13  ;; end
14
15  mov byte [nb], 42
16
17  mov rax, 60
18  mov rdi, 0
19  syscall
```

5.5.4 Exercice 4

```
;; td04_ex4.asm
2
    global main
    section .data
        b0 db 0
7
        b1 db 0
        b2 db 0
9
        b3 db 0
10
    section .rodata
12
        nb dd 0x12_34_56_78
13
14
    section .text
15
16
    main:
17
18
        mov al, [nb]
19
        mov [b0], ax
20
        mov al, [nb+1]
21
        mov [b1], ax
22
        mov al, [nb+2]
23
        mov [b2], al
24
        mov al, [nb+3]
25
        mov [b3], al
26
27
    ;; end
28
29
        mov rax, 60
31
        mov rdi, 0
        syscall
32
```

Attention, vu que les valeurs sont contiguës en mémoire, on peut attribuer nb à b0 en précisant que c'est un dword. Comme ça, on aura bien copié chaque *byte* de nb dans les autres variables.

5.5.5 Exercice **5**

```
mov r8b, [var1]
14
        mov r9b, [var2]
15
        mov [var1], r9b
        mov [var2], r8b
17
18
    ;; end
19
        mov rax, 60
20
        mov rdi, 0
21
        syscall
22
```

5.5.6 Exercice 6

```
;; td04_ex6.asm
    global main
3
    section .data
        var1 db 11
        var2 db 34
    section .bss
10
11
        var3 resb 1
12
13
14
    section .text
15
    main:
16
        mov r8b, [var1]
17
        mov r9b, [var2]
18
        cmp r8b, r9b
19
        js _var1_is_less
20
        mov al, [var2]
21
        jmp _else
    _var1_is_less:
23
        mov al, [var1]
24
25
    _else:
26
        mov [var3], al
27
28
29
    ;; end
        mov rax, 60
31
        mov rdi, 0
32
        syscall
```

6 Laboratoire 5 : Appels système

Ce laboratoire traite des appels systèmes ainsi que leurs arguments, puis de la représentation des chaînes de caractères.

6.1 Définition

Un **appel système** est un service offert par le système d'exploitation pour effectuer diverses tâches comme ouvrir ou lire le contenu d'un fichier. Chaque appel système est identifié par un numéro de service. L'instruction syscall permet de faire basculer le *CPU* en mode privilégié et passe la main au service système demandé. Une fois le code système exécuté, le code reprend à l'instruction suivant le syscall.

6.2 Mise en œuvre

En nasm, le un appel système se fait en quatre étapes :

- 1. Placer le numéro du service désiré dans rax
- 2. Mettre les paramètres, s'il y en a dans rdi, rsi, rdx, rcx, r9, r9.
- 3. Appeler le système via l'instruction syscall.
- 4. Consulter dans rax la valeur de retour, s'il y en a une, ou le statut d'erreur si nécessaire et utile.

Les étapes 1. et 2. peuvent se faire dans l'ordre qu'on veut. Mais tout doit être prêt avant d'exécuter l'instruction syscall. Il faut absolument renseigner le numéro de service dans rax et utiliser les bons registres dans le bon ordre pour les paramètres.

6.3 Registres non préservés

Il est important de savoir que l'instruction syscall utilise les registres :

- rcx pour la sauvegarde de la valeur du registre rip : cela permet, à la fin de l'appel système, le retour au code appelant précisément l'instruction qui suit syscall par la restauration de cette valeur sauvegardée.
- r11 pour la sauvegarde du registre rflags et sa restauration lors du retour au code appelant.

Donc attention, si le contenu de rcx ou r11 est important, il faut le sauver avant l'appel système. Le registre rax est lui aussi modifié, la valeur de retour de l'appel système y est stockée.

6.4 Numéro du service

Pour connaître la liste des numéros de service, il n'y pas d'autre choix que de la consulter.

6.5 Paramètre et retour

Pour connaître les paramètres attendus par un appel système ou savoir s'il retourne une valeur, il faut consulter les man (manuels) de Linux. Plus précisément la section 2.

Là, on peut voir par exemple que le numéro de service de exit est 60 et qu'on lui donne l'argument 0, qui signifie que le processus s'est bien terminé. Dan le cas de exit, aucune valeur n'est retournée.

Si maintenant on se concentre sur l'instruction open, on verra que son premier argument un *pointeur* de *caractères constant*, appelé pathname. On comprend alors que c'est un chemin vers un fichier, sous forme de chaîne de caractères, qui n'est pas modifiée par l'instruction open. On attendra de cette chaîne qu'elle soit zéro-terminé, qu'elle finisse par une byte de zéros pour annoncer que c'est la fin de la chaîne.

Le deuxième argument est une instruction en *octal* qui fournit des indicateurs sur le comportement de l'instruction. On peut combiner plusieurs de ces *flags* avec l'opérateur *pipe* |.

Le troisième argument est attendu dans certains cas suivant le deuxième argument.

Si tout se passe bien, la valeur de retour est un petit entier positif appelé *descripteur de fichier*. C'est par son biais qu'on peut ensuite accéder, écrire, lire ou fermer un fichier ouvert. Cette valeur est retournée dans rax.

Voici un exemple :

```
; 01_open_extrait.asm
   global main
2
   section .rodata
       nomFichier db 'brol', 0 ; ne pas oublier le zéro en fin
5
   section .text
9
       ; ouverture de brol en écriture seule avec placement
10
       ; de la tête d'écriture en fin de fichier
11
12
       mov rax, 2
                          ; open
13
       mov rdi, nomFichier ; /adresse/ du 1er caractère du nom
14
       mov rsi, 1q | 2000q ; WRONLY + O_APPEND
       syscall ; appel système
```

On voit que le nom de fichier utilise des apostrophes simples ', on peut aussi utiliser les doubles " et même les accents ' quand on a besoin de séquences d'échappement. Ici, le nom de fichier est un immédiat de type caractère. C'est un type de variable immuable déclaré dans .rodata, on utilise le *byte* avec l'instruction DB pour le déclarer.

Par exemple,

```
section .rodata

str1 db "abc" ; 3 bytes initialisés

str2 db 'abc', 0 ; 4 (3+1) bytes initialisés, str2 zéro-déterminé

str3 db "abc\n", 0 ; 6 bytes initalisés, zéro-déterminé

str4 db `abc\n`, 0 ; 5 bytes initalisés, zéro-déterminé
```

Pour mesurer la taille d'une chaîne de caractères, on peut faire calculer par nasm le nombre d'espaces adressables entre deux étiquettes. Ces deux étiquettes sont remplacées par les adresses où elles ont été collées, au moment de l'assemblage. On peut utiliser le symbole \$ qui réfère à l'adresse courante.

Le troisième exemple repris dan le TD concerne l'instruction write

6.6 Entrée et sorties standards

Au démarrage d'un programme, trois **flux** sont disponibles sans devoir être ouverts : le flux d'entrée standard stdin, associé par défaut au clavier. Il peut être accédé comme un fichier avec 0 comme valeur de descripteur de fichier.

Le flux de sortie standard, stdout associé par défaut à l'écran, il peut être accédé comme un fichier avec 1 comme valeur de descripteur de fichier.

Le flux de sortie d'erreur standard, stderr, également associé par défaut à l'écran, il peut être accédé comme un fichier avec 2 comme valeur de descripteur de fichier.

6.7 Hello, World!

Voici ce que donne un Hello, World en assembleur.

```
; 02_hello_world.asm
2
   global main
3
   section .rodata
       msg DB `Hello, Wolrd!\n`
6
       lgrMsg DQ lgrMsg - msg
7
   section .text
   main:
10
       ; affichage
11
                           ; write
       mov rax, 1
12
       mov rdi, 1
                          ; stdout
13
       mov rsi, msg
                           ; adresse du 1er caractère
14
       mov rdx, [lgrMsg] ; nombre de caractères
15
       syscall
16
   ; end
17
18
   mov rax, 60
                           : exit
19
   mov rdi, 0
                           ; ok
20
   syscall
```

6.8 Cinq appels système

La table suivante reprend les appels systèmes les plus fréquents ainsi que quelques indications.

Service	Numéro (rax)	But	Paramètres (rdi, rsi, rdx, rcx, r8, r9)	Retour (rax)	Notes
exit	60	quitter un programme	entier à retourner au processus parent, 0 si tout ok	aucun	à mettre en fin de tout programme
open	2	ouvrir ou créer un fichier	1 ^{er} : chemin vers le fichier: chaîne zéro-terminée; 2 ^e : options d'ouverture: indicateurs à combiner avec []; 3 ^e : mode: si création d'un fichier	descripteur de fichier ou entier négatif en cas d'erreur	options d'ouverture : /usr/include/bits/ fcntl-linux.h (voir p. 6)
close	3	fermer un fichier	descripteur du fichier	0 si ok, -1 si erreur	le descripteur de fichier est celui retourné par open
read	0	lire depuis un fichier	1^{er} : descripteur du fichier; 2^{e} : adresse où stocker le résultat de la lecture; 3^{e} : nombre de $bytes$ à lire	nombre d'octets effectivement lus, -1 en cas d'erreur	le descripteur de fichier est celui retourné par open ou 0 pour lire au clavier; la tête de lecture est avancée du nombre de bytes lus
write	1	écrire dans un fichier	 1^{er}: descripteur du fichier; 2^e: adresse de ce qui doit être écrit; 3^e: nombre de bytes à écrire 	nombre d'octets effectivement écrits, -1 en cas d'erreur	— le descripteur de fichier est celui retourné par open ou 1 pour écrire à l'écran; — la tête d'écriture est avancée du nombre de bytes écrits

6.9 Exercices

6.9.1 Ouvrir un fichier

Quand le fichier brol existe avec droit d'écriture, on le code 3 qui indique le descripteur de fichier, tout se déroule correctement.

Quand on a pas de droit d'écriture, on a une erreur et rax contient -13.

Quand le fichier brol n'existe pas, on a aussi une erreur et rax contient -2.

Une fois qu'on change les arguments donnés à l'ouverture de fichier :

Quand le fichier brol existe avec droit d'écriture, on a le code 3 qui indique le descripteur de fichier, tout se déroule correctement.

Quand le fichier n'a pas de droit d'écriture, on a une erreur et rax contient -13.

Par contre, quand brol n'existe pas, on réussi à l'écrire dans ce cas-ci et rax contient 3.

6.9.2 Ouverture et écriture

```
;; td05_ex2.asm
2
   global main
3
   section .rodata
5
       nomFichier db `brol`, 0 ; nécessaire pour le nom du fichier
       msgOK
                 db `fichier ouvert avec succès\n`, 0
7
       len0k
                  dq $ - msgOK
       msgFail db `échec lors de l'ouverture du fichier\n`, 0
9
       lenFail dq $ - msgFail
11
   section .text
12
   main:
13
14
       mov rax, 2
15
                                          ;open
       mov rdi, nomFichier
                                           ; fichier
16
       mov rsi, 0q
                                           ; RONLY
17
       syscall
18
19
       cmp rax, 0
20
       js _fail
21
22
    ;; affichage
       mov rbx, rax
                                    ; sauver le descripteur du fichier
23
                                         ; write
       mov rax, 1
24
```

```
mov rdi, 1
                                           ; stdout
25
        mov rsi, msgOK
                                      ; adresse du premier char
26
        mov rdx, [len0k]
                                        ; nombre de caractères
27
28
        syscall
29
        mov rax, 3
                                           ; close
30
        mov rdi, rbx
                                     ; descripteur du fichier
31
        syscall
32
33
                                             ; end
        mov rax, 60
34
        mov rdi, 0
                                            ; zero, pas d'erreur
35
        syscall
37
    _fail:
38
       mov rax, 1
                                           ; write
39
        mov rdi, 1
                                             ; stdout
       mov rsi, msgFail
                                         ; message d'erreur, adresse du premier char
41
        mov rdx, [lenFail]
                                           ; nombre de caractères
42
        syscall
43
        mov rax, 60
                                     ; end
45
        mov rdi, 1
                                            ; 1, erreur
46
        syscall
```

6.9.3 Convertir rsi en caractères

```
;; td05_ex3.asm
2
    global main
    section .bss
5
         charToShow resb 1
    section .text
8
    main:
         mov rsi, 7
11
         or rsi, 00110000b ; masque pour convertir en ASCII
mov [charToShow], rsi ; Place la valeur de rsi dans la variable
12
13
14
15
     ;; affichage
16
         mov rax, 1
                                                   ; write
17
         mov rdi, 1
                                                 ; stdout
                                                  ; Adress du premier caractère
         mov rsi, charToShow
19
         mov rdx, 1
                                                  ; On lit exactement 1 byte
20
         syscall
21
22
     ;; end
23
24
25
         mov rax, 60
         mov rdi, 0
         syscall
```

Le code fonctionne mais quand on met une valeur plus grande que 9, le masque booléen converti la valeur une valeur ASCII différente, par exemple la valeur 15 devient le caractère point d'interrogation.

6.9.4 Afficher la parité

```
;; td05_ex4.asm
```

```
global main
3
    section .rodata
4
                        db `Le contenu est pair\n`
        pairMessage
5
        lenPair
                         dq $ - pairMessage
        impairMessage db `Le contenu est impair\n`
                      dq $ - impairMessage
        lenImpair
    section .text
    main:
        mov rcx, 11
11
12
        bt rcx, 0
                                             ; Donne la valeur du 1er bit donc 1 si impair
13
        jc _impair
14
15
        mov rax, 1
                                              ; write
16
        mov rdi, 1
                                             ; stdout
17
        mov rsi, pairMessage ; adresse du 1er caractère
18
        mov rdx, [lenPair]
                                         ; longueur du message
19
        syscall
20
        jmp _end
21
22
    _impair:
23
                                                       ; write
        mov
                     rax, 1
24
        mov rdi, 1
                                             ; stdout
25
        mov rsi, impairMessage ; adresse du 1er car
mov rdx, [lenImpair] ; longueur du message
                                        ; adresse du 1er caractère
26
27
        syscall
28
29
    _end:
30
31
        mov rax, 60
32
        mov rdi, 0
33
        syscall
```

6.9.5 Écrire des fichiers

```
;; td05_ex5.asm
3
   global main
   section .bss
4
      var resq 1
                                           ; Réserve 1x8 bytes
5
   section .rodata
      nomPair db
                      `pair`, 0
       nomImpair db `impair`, 0
   section .text
10
11
   main:
12
13
14
       mov rcx, 77
       mov qword [var], rcx ; sauver le contenu de rcx
15
16
       bt rcx, 0
                                           ; CF prend la valeur du Oeme bit de rcx
17
       jc _impair
18
19
                                           ; open
       mov rax, 2
20
       mov rdi, nomPair
                                        ; adresse du 1er caractère du nom
21
                                           ; WRONLY
       mov rsi, 1q
22
       syscall
23
       jmp _write
24
25
    _impair:
   mov rax, 2
                                           ; open
27
```

```
mov rdi, nomImpair
                                                      ; adresse du 1er caractère du nom
28
                                                        ; WRONLY
          mov rsi, 1q
29
          syscall
30
31
    _write:
32
       mov rbx, rax ; sauver le descripteur
mov rax, 1 ; write
mov rdi, rbx ; descripteur du fichier
mov rsi, var ; adresse de ce qui doit être écrit
33
34
35
36
       mov rdx, 8
                                                       ; Nombre de bytes à écrire
37
        syscall
38
39
    ;; end
40
        mov rax, 60
41
         mov rdi, 0
42
       syscall
```

6.9.6 Stocker une taille de fichier

À faire.